PoD ACADEMY

Análise Exploratória de Dados (EDA)

Agenda

1. Introdução à Análise de Dados e Análise Exploratória de Dados
2. Por que, Quando, Onde e Quem Realiza a Análise de Dados?
3. Ferramentas para Análise de Dados
4. Como Realizar uma Análise Exploratória de Dados Completa
5. Pensamento Analítico e Tomada de Decisão Baseada em Dados
6. Preparação dos Dados
7. Conceitos de Matemática e Estatística
8. Visualização de Dados e Gráficos Comuns
9. Estudo de Caso

Introdução à Análise de Dados e Análise Exploratória de Dados

O que é Análise de Dados e EDA?

- Definição de análise de dados e papel da EDA no processo.
- Diferença entre dados estruturados e não estruturados.
- Exemplos de tipos de dados e sua aplicação no contexto empresarial.
    - Ex.: Dados transacionais, dados demográficos, dados comportamentais

Importância dos Dados no Contexto de Negócios

- Como dados orientam decisões estratégicas.
    - Ex.: Marketing e Vendas, Operações e Logística, RH...
- Casos de uso de dados em diversas indústrias.
    - Ex.: Varejo, Saúde, Finanças, Tecnologia...

Por que, Quando, Onde e Quem Realiza a Análise de Dados?

Por que é feita?

- Objetivos principais da análise de dados: insight, otimização, inovação.

Quando e Onde?

- Momentos ideais para utilizar a análise de dados (ex.: análise de mercado, melhoria de processos).
- Ambientes onde a análise ocorre: empresas, setores governamentais, startups, etc.

Quem faz?

- Perfis profissionais que realizam EDA: cientistas de dados, analistas de negócios, engenheiros de dados, analistas de modo geral...

Ferramentas para Análise de Dados

Ferramentas de Programação

- Python (NumPy, Pandas, Matplotlib, Seaborn)
- Excel
- SQL

Ferramentas de Visualização

- Power BI,
- Tableau,
- Metabase

Apresentação de Resultados

- PowerPoint

Ferramentas para Análise de Dados

Python (NumPy, Pandas, Matplotlib, Seaborn)

- **Como conectar, quando e por que usar**: Python é uma linguagem poderosa para análise de grandes volumes de dados e criação de visualizações customizadas. Ele é especialmente útil em cenários que exigem automação e replicabilidade de processos, além de integração com outras plataformas e ferramentas.
  - **Funções principais para manipulação e visualização de dados:**
    - **NumPy**: Usado para cálculos matemáticos e operações eficientes com arrays e matrizes.
      - Funções principais: `np.array()`, `np.mean()`, `np.median()`, `np.std()`, `np.var()`, `np.unique()`, `np.concatenate()`, `np.reshape()`.
    - **Pandas**: A principal biblioteca para manipulação de dados, permitindo a leitura, limpeza e transformação de grandes conjuntos de dados de forma rápida e eficaz.
      - Funções principais: `pd.read_csv()`, `pd.DataFrame()`, `df.head()`, `df.tail()`, `df.info()`, `df.describe()`, `df.isnull()`, `df.fillna()`, `df.dropna()`, `df.groupby()`, `df.merge()`, `df.pivot_table()`, `df.value_counts()`, `df.corr()`, `df.apply()`, `df.astype()`, `df.replace()`, `df.sample()`.
    - **Matplotlib e Seaborn**: Bibliotecas voltadas para a visualização de dados.
      - **Matplotlib**: `plt.plot()`, `plt.bar()`, `plt.scatter()`, `plt.hist()`, `plt.boxplot()`, `plt.title()`, `plt.xlabel()`, `plt.ylabel()`, `plt.show()`, `plt.subplot()`, `plt.xticks()`, `plt.yticks()`.
      - **Seaborn**: `sns.scatterplot()`, `sns.lineplot()`, `sns.histplot()`, `sns.boxplot()`, `sns.heatmap()`, `sns.pairplot()`, `sns.violinplot()`, `sns.catplot()`, `sns.set_style()`, `sns.set_palette()`.

Ferramentas para Análise de Dados

Excel

- **Uso para análise rápida e visualizações simples**: Embora o Excel seja limitado em comparação com Python e outras ferramentas mais robustas, ele é ideal para análises rápidas, pequenos conjuntos de dados e visualizações simples.
- **Principais fórmulas e funcionalidades**:
  - **Procurar e Referenciar**: `VLOOKUP()`, `HLOOKUP()`, `INDEX()`, `MATCH()`, `XLOOKUP()`.
  - **Manipulação de dados**: `CONCATENATE()`, `TEXT()`, `TRIM()`, `LEFT()`, `RIGHT()`, `MID()`.
  - **Cálculos condicionais**: `SUMIFS()`, `AVERAGEIFS()`, `COUNTIFS()`, `IF()`, `IFS()`, `SUMPRODUCT()`.
  - **Análise Estatística**: `STDEV.P()`, `STDEV.S()`, `VAR.P()`, `VAR.S()`, `CORREL()` , `SUM()` , `MIN()`, `MAX()`...
  - **Gráficos**: Criação de gráficos de barras, pizza, dispersão e gráficos dinâmicos.
  - **Tabelas Dinâmicas**: Utilização de Tabelas Dinâmicas para sumarização e análise de grandes volumes de dados.
  - **Filtros e Slicers**: Uso de filtros para explorar subconjuntos de dados e Slicers para facilitar a interação com Tabelas Dinâmicas.

Ferramentas para Análise de Dados

SQL

- **Bancos de dados:** conexão a bancos de dados relacionais, como MySQL, PostgreSQL ou SQL Server, para extrair dados de forma eficiente.
- **Funções principais e uso em extração e manipulação de dados:**
  - **Consultas:** `SELECT`, `FROM`, `WHERE`, `ORDER BY`, `LIMIT`.
  - **Agregação:** `COUNT()`, `SUM()`, `AVG()`, `MIN()`, `MAX()`, utilizando com `GROUP BY` e `HAVING`.
  - **Joins:** `INNER JOIN`, `LEFT JOIN`, `RIGHT JOIN`, `FULL JOIN`, `CROSS JOIN`, para combinar dados de diferentes tabelas.
  - **Subconsultas:** Uso de subconsultas em cláusulas `WHERE` ou `FROM`.
  - **Manipulação de dados:** `INSERT INTO`, `UPDATE`, `DELETE`.
  - **Criação e modificação de tabelas:** `CREATE TABLE`, `ALTER TABLE`, `DROP TABLE`.
  - **Funções de janela (Window Functions):** `ROW_NUMBER()`, `RANK()`, `DENSE_RANK()`, `NTILE()`, `LEAD()`, `LAG()` para análises mais complexas sobre conjuntos de dados.
  - **Funções de string:** `CONCAT()`, `SUBSTRING()`, `CHAR_LENGTH()`, `UPPER()`, `LOWER()`, `TRIM()`, `REPLACE()` para manipulação de dados textuais.

Como Realizar uma Análise Exploratória de Dados Completa

Passo a Passo de EDA

- Entendimento do Problema de Negócio
- Entendimento dos dados.
- Exploração inicial e geração de hipóteses.
- Limpeza e formatação dos dados.
- Visualização de padrões e tendências.
- Extração de insights e recomendações finais.

Estudo de Caso

- Aplicação prática de uma análise exploratória.

Pensamento Analítico e Tomada de Decisão Baseada em Dados

Definição de problemas e hipóteses

- Análise de dados voltado para resolução do problema de negócio.
- Como formular perguntas corretas.
  - Definição clara do problema.
  - Formulação de hipóteses

Insights e recomendações ao negócio

- Como transformar dados em insights acionáveis.
- Comunicar as descobertas de maneira clara.

Tomada de Decisão Baseada em Dados

- Exemplos de decisões informadas por dados
- Importância do processo analítico.

Exemplos de Decisões Informadas por Dados

- **Marketing:** Uso de dados de comportamento de clientes para ajustar campanhas publicitárias e aumentar a taxa de conversão.
- **Operações**: Ajustes em processos de produção ou logística com base em análises de eficiência e custos.
- **Recursos Humanos:** Melhoria nas estratégias de retenção de talentos usando dados de satisfação e desempenho dos colaboradores.

Entendimento e Preparação dos Dados

Tratamento de Tipos de Dados

- Como lidar com diferentes tipos de colunas e dados:
  - Numéricos: idade, salário, número de vendas;
  - Categóricos: gênero, estado civil, setor, produto;
  - Datas: datas de transação, registros de login, duração de eventos.

Cardinalidade, Duplicidade, e Nomes de Colunas

- A importância da consistência e normalização de dados.

Valores Nulos e Missing Data

- Análise de valores nulos e missing;
- Estratégias para lidar com dados ausentes: remoção ou imputação.

Conceitos Fundamentais de Matemática e Estatística

Média, Mediana, Moda e Quartis

- Conceitos básicos de medidas centrais.
  - **Média**: A média aritmética é a soma de todos os valores dividida pela quantidade de observações. Ela é amplamente utilizada, mas pode ser sensível a outliers.
  - **Mediana**: A mediana é o valor central de um conjunto de dados ordenados. É uma medida mais robusta que a média, especialmente quando os dados contêm outliers, já que não é afetada por valores extremos.
  - **Moda**: A moda é o valor que mais aparece em um conjunto de dados. É útil em dados categóricos ou quando se deseja identificar a frequência de uma categoria específica.
  - **Quartis**: Os quartis dividem os dados em quatro partes iguais. O primeiro quartil (Q1) representa o ponto onde 25% dos dados estão abaixo, o terceiro quartil (Q3) representa o ponto onde 75% dos dados estão abaixo, e a diferença entre Q3 e Q1, chamada de **intervalo interquartil (IQR)**, é uma importante medida de dispersão para identificar outliers.

Conceitos Fundamentais de Matemática e Estatística

Variância e Desvio Padrão

- Medidas de Dispersão e Sua Interpretação
  - **Variância**: A variância mede o grau de dispersão dos dados ao calcular a média dos quadrados das diferenças entre cada ponto e a média. Valores altos indicam que os dados estão dispersos em relação à média, enquanto valores baixos indicam que os dados estão concentrados próximos à média.
  - **Desvio Padrão**: O desvio padrão é a raiz quadrada da variância e oferece uma interpretação mais direta da dispersão em relação à média. Ele é uma métrica útil para compreender o quão "espalhados" os dados estão em relação ao valor médio, sendo utilizado frequentemente em finanças, controle de qualidade, entre outras áreas.

Conceitos Fundamentais de Matemática e Estatística

Distribuições de Probabilidade

- Compreensão das Distribuições Normais e Outros Tipos Comuns.
  - **Distribuição Normal**: Também conhecida como distribuição Gaussiana, é uma das mais importantes no campo da estatística. A curva normal é simétrica e tem a maioria dos dados concentrados ao redor da média, com menos dados nas extremidades (caudas). Muitos fenômenos naturais e econômicos seguem uma distribuição normal, o que a torna central em análises de dados e inferências.
  - **Outras Distribuições**: Além da normal, existem outras distribuições como a Binomial, que descreve o número de sucessos em uma sequência de experimentos binários, e a Poisson, que modela a ocorrência de eventos raros em um intervalo de tempo ou espaço. Compreender essas diferentes distribuições permite modelar adequadamente fenômenos específicos e prever resultados com maior precisão.

Conceitos Fundamentais de Matemática e Estatística

Correlação de Pearson e Regressão

- Introdução às Técnicas de Correlação e Regressão para Entender Relações entre Variáveis
  - **Correlação de Pearson**: A correlação mede a força e a direção da relação linear entre duas variáveis. O coeficiente de correlação de Pearson, por exemplo, varia de -1 a 1, onde valores próximos de 1 indicam uma forte correlação positiva, valores próximos de -1 indicam uma forte correlação negativa, e valores próximos de 0 indicam pouca ou nenhuma correlação. A correlação ajuda a identificar padrões e prever como mudanças em uma variável podem impactar outra.
  - **Regressão Linear**: A regressão vai além da correlação e permite prever valores de uma variável com base em outra. Na **regressão linear simples**, um modelo linear é ajustado para descrever a relação entre uma variável independente (input) e uma variável dependente (output). A **regressão linear múltipla** estende esse conceito para múltiplas variáveis independentes.

Visualização de Dados e Gráficos Comuns

Tipos de Gráficos Mais Comuns

- Gráficos de barras, linhas, dispersão, boxplots.
- Histograma, heatmaps, gráficos de pares, e matrizes de correlação.

Fluxograma "Qual gráfico usar?":

- https://www.mindmeister.com/app/map/3447382477?t=tpKpsTcEoR

Por que Utilizar Cada Gráfico?

- Correspondência de gráficos com tipos de dados e variáveis (categóricas vs. numéricas).

Quando Utilizar Cada Gráfico?

- **Análise Univariada**: Distribuições simples de uma variável.
- **Análise Bivariada**: Relacionamento entre duas variáveis.
- **Análise Multivariada**: Exploração de múltiplas variáveis e interações complexas.
- **Análise e Tratamento de Outliers:** Identificação e visualização de outliers usando boxplots e gráficos de dispersão.

Estudo de Caso

Análise de Vendas Farmacêuticas

- Em Python;
- Em Excel.

PoD ACADEMY

Rafael Salomão

Cientista de Dados - PowerOfData